Semistrukturierte Daten

Sommersemester 2014

Teil 5: Java API for XML Processing

5.1. Überblick
5.2. SAX (Simple API for XML)
5.3. DOM (Document Object Model)
5.4. Serialisierung von XML Daten
5.5. Epilog

5.1. Überblick

- XML-APIs und Java
- XML-Prozessor (Parser)
- Parser-Modelle

XML-APIs und Java

- Die wichtigsten XML-APIs (DOM und SAX) sind eigentlich programmiersprachen-unabhängig. In der SSD-Vorlesung werden aber nur die Java-Realisierungen behandelt.
- JAXP (Java API for XML-Processing):
  - Teil von JDK ab Version 1.4
  - Enthält Java-Realisierung von DOM und SAX sowie ein XSLT-API (TrAX: Transformation API for XML)
- Wichtige JAXP-Packages:
  - javax.xml.parsers (gemeinsames Interface für SAX und DOM Parser von unterschiedlichen Herstellern).
  - org.w3c.dom
  - org.xml.sax
  - javax.xml.transform

Idee eines XML-Prozessors (Parsers)

- Stellt der Applikation eine einfache Schnittstelle zum Zugriff auf ein XML-Dokument (plus eventuell zum Manipulieren und wieder Abspeichern des XML-Dokuments) zur Verfügung.
- Fokus auf die logische Struktur bzw. den Inhalt des XML-Dokuments (und nicht auf die exakte Syntax) => wesentlich flexibler/robuster als Text-Parsen.

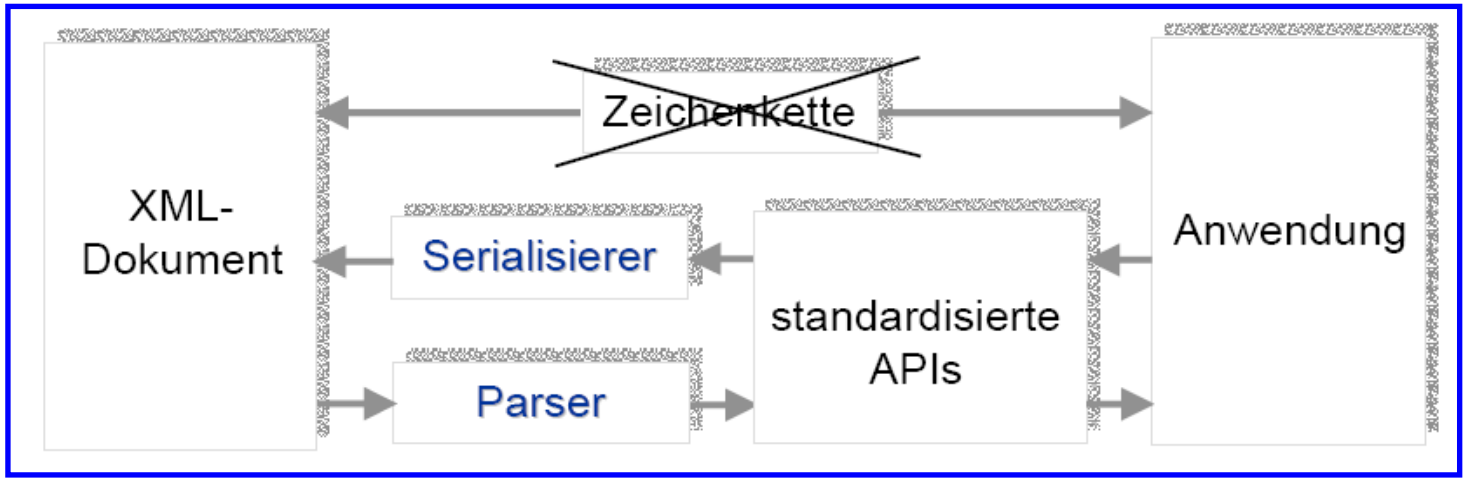

Aufgaben eines XML-Prozessors (Parsers)

- Überprüfung der Wohlgeformtheit und (optional) der Gültigkeit
- Ergänzung von default/fixed-Werten
- Auflösen von internen/externen Entities und Character References
- Normalisierung von Whitespace

Parser-Modelle

- Objektmodell Parser:
  - Baut gesamten XML-Baum im Speicher auf => wahlfreier Zugriff
  - Beispiele: DOM, JDOM
- Push Parser (ereignisorientiert, Parser kontrolliert Ablauf):
  - XML-Dokument wird einmal durchlaufen => sequentieller Zugriff
  - Applikation kann für die möglichen "Events" (d.h. syntaktische Einheiten) callback Funktionen bereitstellen
  - Beispiel: SAX
- Pull Parser (ereignisorientiert, Applikation kontrolliert Ablauf):
  - XML-Dokument wird einmal durchlaufen => sequentieller Zugriff
  - Applikation fordert Analyse der nächsten syntaktischen Einheit an
  - Beispiel: StAX (mittlerweile Teil von Java als SJSXP, "Sun Java Streaming XML Parser")

5.2. Simple API for XML (SAX)

- Entwicklung von SAX
- Funktionsweise von SAX
- ContentHandler
- Weitere Eventhandler
- XMLReader
- SAX Filter

Entwicklung von SAX

- SAX: Simple API for XML
- keine W3C Recommendation, aber ein de-facto Standard: http://www.saxproject.org/
- Free and Open Source Software (SourceForge)
- Plattform- und Programmiersprachen-unabhängig (auch wenn SAX ursprünglich für Java entwickelt wurde)
- SAX Versionen:
  - SAX 1.0: entstanden auf Initiative von Peter Murray-Rust (mit dem Ziel, mehrere ähnliche aber inkompatible Java XML-APIs zusammenzuführen), im Mai 1998 freigegeben.
  - SAX 2.0: erweitert um Namespace-Unterstützung; nicht kompatibel zu SAX 1.0 (Aktuell SAX 2.0.1)

Funktionsweise von SAX

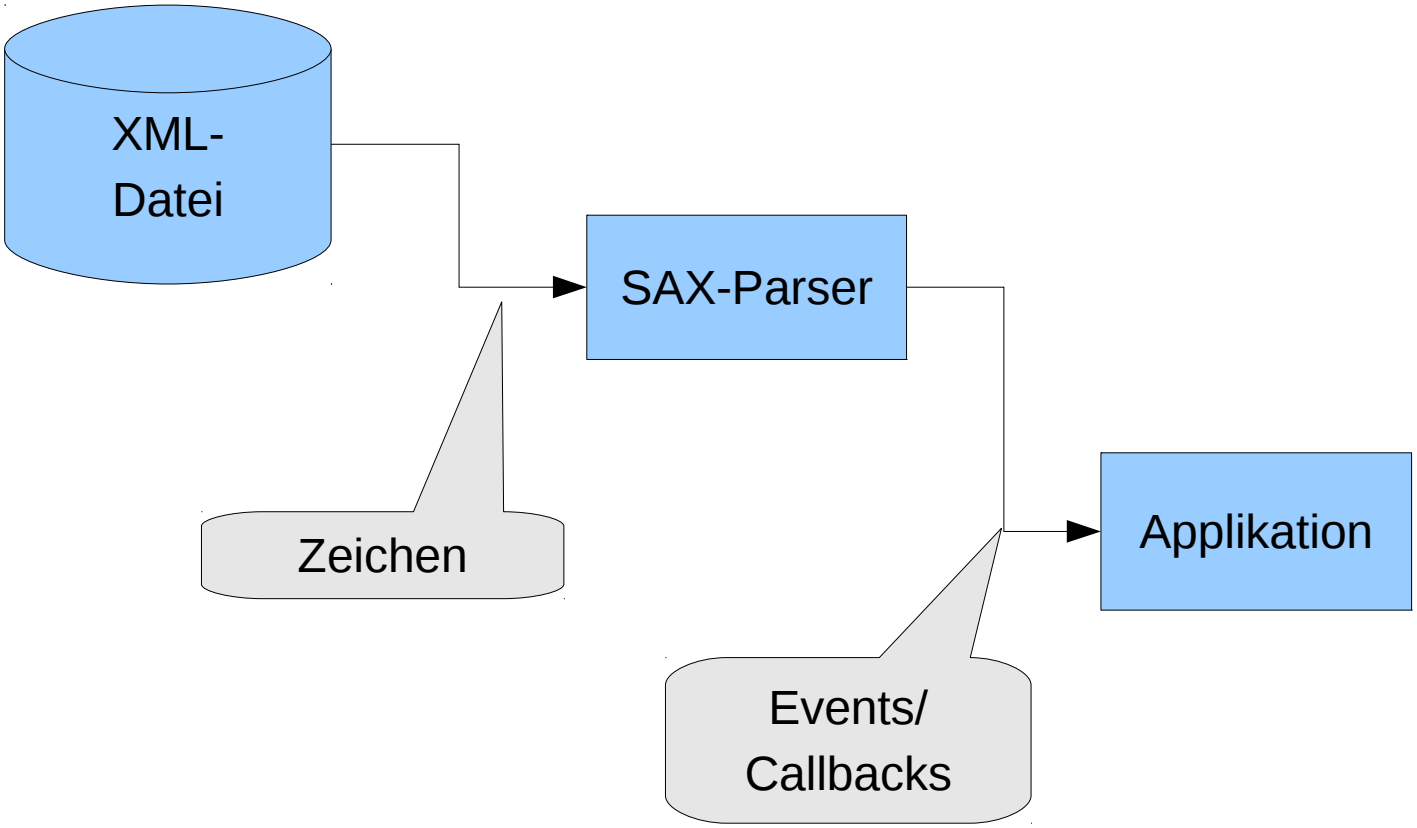

Funktionsweise von SAX

- Applikation registriert callback Funktionen beim SAX-Parser.
- Applikation stößt den Parser an.
- SAX-Parser durchläuft das XML-Dokument einmal sequentiell.
- Parser erkennt syntaktische Einheiten des XML-Dokuments.
- Parser ruft für jedes Event die entsprechende callback Funktion auf.
- Diese callback Funktionen sind auf 4 Event Handler aufgeteilt: ContentHandler, ErrorHandler, DTDHandler, EntityResolver

Einfaches Beispiel

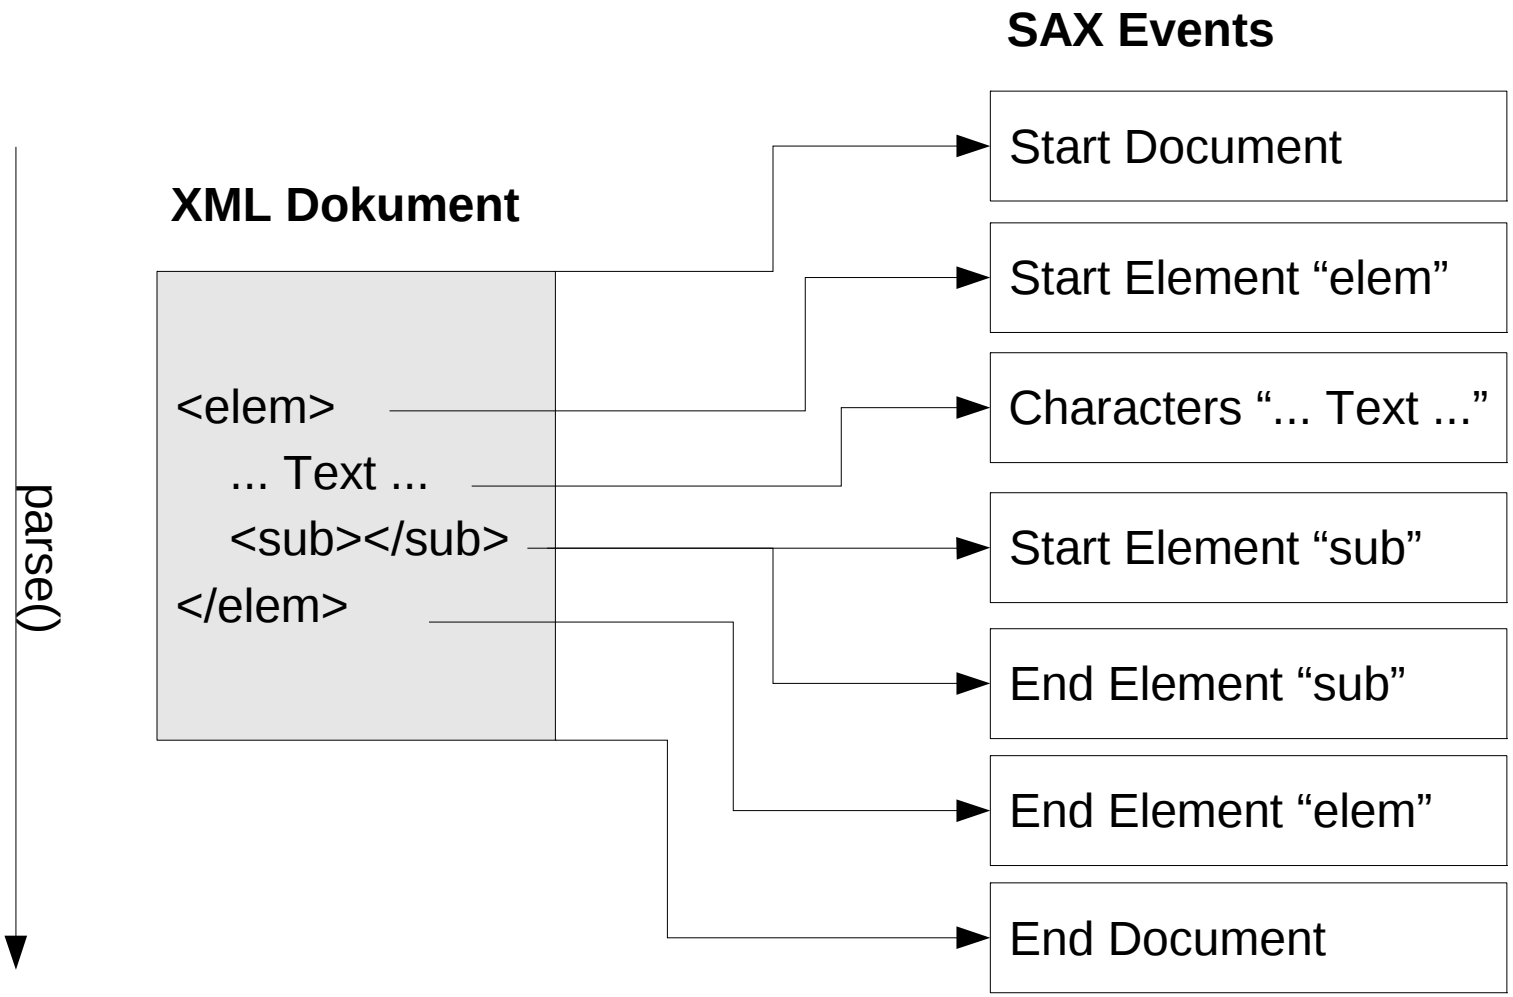

XML Reader (Preview)

- Ist der eigentliche SAX-Parser, d.h.: liest das XML-Dokument und ruft die callback Funktionen auf.
- Erzeugen des XML Readers:
  ```
  XMLReader xr = XMLReaderFactory.createXMLReader();
  ```
- Registrieren der callback Funktionen
  ```
  xr.setContentHandler(ContentHandler ch);
  ...
  ```
- Methode zum Anstoßen des Parsers:
  ```
  xr.parse(InputSource is);
  ```

ContentHandler

- Überblick
- einige ContentHandler-Methoden im Detail:
  - Dokument-Verarbeitung
  - Element-Verarbeitung
  - Attributes Interface
  - Text-Verarbeitung
  - Locator-Interface
- DefaultHandler

Überblick: Methoden des ContentHandler (1)

```
void startDocument()
void endDocument()
void startElement(String namespaceURI,
      String localName, String qName, Attributes atts)
void endElement(String namespaceURI, String localName,
      String qName)
void characters(char[] ch, int start, int length)
void setDocumentLocator(Locator locator)
void processingInstruction(String target, String data)
// target: z.B. "xml-stylesheet". data: unstrukturierter Rest
// d.h.: Pseudo-Attribute werden nicht erkannt wie z.B.:
// <?xml-stylesheet type="text/css" href="order.css"?>
```

Überblick: Methoden des ContentHandler (2)

```
void ignorableWhitespace(char[] ch, int start,
     int length)
// bei validierendem Parsers: meldet ignorable whitespace mit
// diesem Event und nicht als "characters" (meist reicht DTD)
void skippedEntity(String name)
// falls Parser die (externe) DTD nicht liest, meldet er
// eine Entity Referenz mit diesem Event (anstatt die
// Entity zu expandieren und als "characters" zu melden.
void startPrefixMapping(String prefix, String uri)
void endPrefixMapping(String prefix)
// nur interessant, wenn man auf ein Prefix in einem
// Attribut-Wert zugreift (z.B. bei XML-Schema)
```

Dokument-Verarbeitung

```
void startDocument()
void endDocument()
```

- Ein XMLReader + ContentHandler kann für die Verarbeitung mehrerer Dokumente (hintereinander!) verwendet werden.

  => Initialisierungen am besten in **`startDocument`**

- Wohlgeformtheitsfehler:
  - werden vom Parser erst erkannt, nachdem er schon etliche Events geliefert hat. => dessen muss man sich beim Verarbeiten von Events bewusst sein (d.h.: ev. Rückrollen erforderlich).
  - Allfälliger clean-up code in **`endDocument`** wird ev. nie ausgeführt.
- Reader ist weder thread-safe noch reantrant.

  => Parallele Verarbeitung von mehreren Dokumenten erfordert mehrere Reader Objekte.

Element-Verarbeitung

```
void startElement(String namespaceURI,
     String localName, String qName, Attributes atts)
void endElement(String namespaceURI, String localName,
     String qName)
```

- Argumente:
  - namespaceURI: leerer String bei Element ohne Namespace
  - qName = Präfix + ":" + localName
  - atts: siehe nächste Folie
- SAX hat absolut kein "Gedächtnis".

  => Häufig verwendete Datenstruktur in der Applikation:

  Stack für die offenen Elemente:
  - bei **`startElement`**: push Element-Informationen
  - bei **`endElement`**: pop

Attributes Interface

- **`startElement`** liefert Attribute als Attributes Objekt zurück.
- Zugriff mittels **`getLength()`**und Attribut-Index:

```
String getLocalName(int index)
String getURI(int index)
String getQName(int index)
String getType(int index)
```

- Zugriff mittels Namespace-qualified name:

```
int getIndex(String uri, String localName)
String getValue(String uri, String localName)
String getType(String uri, String localName)
```

- Analog: Zugriff mittels qualified (prefixed) name, z.B.:

```
int getIndex(String qualifiedName)
```

Text-Verarbeitung

```
void characters(char[] ch, int start, int length)
```

- Darstellung von Text-Inhalt:
  - als Char-Array mit Start-Index und Längenangabe
  - (insbes. bei langem Text): SAX-Parser darf Text auf beliebig viele hintereinander folgende **`characters`** Events aufteilen.
- Häufige Verarbeitungsart:
  - Text-Inhalt in einem StringBuffer akkumulieren
  - bei Element-Event: Ausgabe und Initialisierung eines StringBuffer

Locator Interface

- Das Locator Interface erlaubt Zugriff auf die Stelle im Dokument, wo das letzte Event gefunden wurde.
- SAX-Parser sollte (muss aber nicht) Locator implementieren.
- Methoden, z.B.:

```
int getLineNumber()
int getColumnNumber()
```

- Typischer Code, um Locator-Information verfügbar zu haben:
  - Instanz-Variable für ContentHandler Objekt definieren:

```
private Locator locator;
```

  - Referenz auf Locator abspeichern:

```
public void setDocumentLocator(Locator locator) {
   this.locator = locator;
}
```

DefaultHandler

- Deklaration des DefaultHandlers (in org.xml.sax.helpers):

```
public class DefaultHandler extends Object
implements EntityResolver, DTDHandler,
    ContentHandler, ErrorHandler
```

- Enthält default-Deklarationen für alle callback Funktionen dieser 4 Event Handler
- Default-Verhalten: "do nothing"-Methoden
- Bequeme Definition eines eigenen Handlers:
  - von DefaultHandler erben
  - die tatsächlich benötigten callback Funktionen überschreiben

Weitere Event Handler

- EntityResolver
- DTDHandler
- ErrorHandler

EntityResolver

- Einzige Methode:

```
InputSource resolveEntity(String publicId, String systemId)
```

- Idee:
  - Die **`resolveEntity`**-Methode wird vom Parser aufgerufen, wenn eine externe geparste Entity gefunden wurde.
  - externe geparste Entities können mittels SystemId oder PublicId angegeben werden.
  - Mittels **`resolveEntity`** Methode bekommt die Applikation die Möglichkeit (insbes. bei PublicId) dem Parser eine andere InputSource bereitzustellen.

DTDHandler

- Methoden:

```
void notationDecl(String name, String publicId,
 String systemId)
void unparsedEntityDecl(String name, String publicId,
 String systemId, String notationName)
```

- Idee:
  - Während der Bearbeitung der DTD meldet der Parser die Deklarationen von Notations und unparsed Entities.
  - Die Applikation speichert sich diese Informationen in eigenen Datenstrukturen (z.B. in Hash Tabelle)
  - Wenn der Parser Attribute vom Typ "NOTATION", "ENTITY" oder "ENTITIES" meldet, hat die Applikation die nötigen Informationen.

ErrorHandler

- Methoden:

```
void fatalError(SAXParseException exception)
// non-recoverable error
void error(SAXParseException exception)
void warning(SAXParseException exception)
```

- Idee:
  - Bei Wohlgeformtheitsfehler wirft der Parser eine Exception und beendet den Parse-Vorgang.
  - Bei anderen Fehlern (insbes. Gültigkeitsfehler bei validierendem Parser) kann der Parser fortsetzen und wirft keine Exception.
  - Benachrichtigung der Applikation: Parser reicht SAXParseException an die entsprechende Methode des ErrorHandlers.

XMLReader

- Reader-Implementierung
- Features und Properties

XML Reader

- Ist der eigentliche SAX-Parser, d.h.: liest das XML-Dokument und ruft die callback Funktionen auf.
- Erlaubt das Setzen/Auslesen bestimmter Properties/Features:

  `setFeature, setProperty, getFeature, getProperty`
- Benutzer registriert die Event Handler (mit den callback Funktionen):

  `setContentHandler, setDTDHandler,`
  `setEntityResolver, setErrorHandler`
- Analog dazu get-Methoden für die Event Handler:

  `getContentHandler, getDTDHandler,` etc.
- Methode zum Anstoßen des Parsers:

  `parse`

Reader-Implementierung

- XMLReader Instanz mittels XMLReader Factory erzeugen
- Auswahl einer bestimmten Implementierung:
  - Default-Implementierung auswählen:

```
public static XMLReader createXMLReader()
    throws SAXException;
// Auswahl des SAX-Parsers laut system property
// org.xml.sax.driver (kann mit Kommandozeilen-
// parameter "-D" gesetzt werden)
```

  - Auswahl einer bestimmten Implementierung:

```
public static XMLReader createXMLReader(
    String className) throws SAXException;
// className = gewünschte Implementierung,
// z.B.: "org.apache.xerces.parsers.SAXParser"
```

Features und Properties

XMLReader-Methoden:

- `boolean getFeature(String name) throws SAXNotRecognizedException, SAXNotSupportedException`
- `Object getProperty(String name) throws SAXNotRecognizedException, SAXNotSupportedException`
- `void setFeature(String name, boolean value) throws SAXNotRecognizedException, SAXNotSupportedException`
- `void setProperty(String name, Object value) throws SAXNotRecognizedException, SAXNotSupportedException`

Features

- Haben einen boolean Wert: true / false
- Feature-Namen sind absolute URLs
- Standard-Features (z.B. validierend, Namespace-aware, ...)

```
parser.setFeature(
 "http://xml.org/sax/features/validation", true);
parser.setFeature(
 "http://xml.org/sax/features/namespaces", true);
```

- Vendor-spezifische Features, z.B.:

```
boolean schemaValidierend = parser.getFeature(
 "http://apache.org/xml/features/validation/schema");
boolean schemaFullChecking = parser.setFeature(
 "http://apache.org/xml/features/validation/schema-full-
 checking");
```

Properties

- Haben einen "beliebigen" Typ, z.B.:
  - Property **`"http://xml.org/sax/properties/lexical-handler"`**
    `(ermöglicht Zugriff auf Kommentare, CDATA Sections, …)`
    `=>` das konkrete handler-Objekt wird als Property gesetzt/gelesen.
- Property-Namen sind absolute URLs
- Weitere Standard-Properties, z.B.:
  - Property **`"http://xml.org/sax/properties/xml-string"`**
    read-only Property: liefert den Text-String, der das aktuelle SAX-Event ausgelöst hat.
- Vendor-spezifische Properties, z.B.:
  - Property **`"http://apache.org/xml/properties/schema/external-schemaLocation":`** gibt an, wo der Parser nach XML-Schema Dateien suchen soll.

SAX-Filter

- Funktionsweise eines SAX-Filters
- Verwendung eines SAX-Filters

Funktionsweise eines SAX-Filters

- Filter beschränken/manipulieren auftretende Events
- Filter können verschachtelt verwendet werden
- Falls sich Dokumentstruktur ändert, kann eine Adaption des Filters ausreichend sein (also: ohne die Applikation zu ändern).
- Bemerkung: Filter kann auch für nicht XML-Input verwendet werden (ohne dass die Client-Applikation das merkt...)

Funktionsweise eines SAX-Filters (2)

- Vorbereitung:
  - Applikation teilt dem Filter mit, auf welchen Reader er horchen muss
  - Applikation registriert ihre Event Handler beim Filter
- Start des Parse-Vorgangs:
  - Applikation ruft parse()-Methode des Filters auf
  - Filter ruft parse()-Methode des Readers auf
- Parse-Vorgang:
  - Reader erzeugt Events => ruft callback Funktionen *des Filters* auf
  - Filter ruft innerhalb seiner callback Funktionen die callback Funktionen der Applikation auf.
- Der Filter ist also gleichzeitig Event Handler und Reader.

Verwendung eines SAX-Filters

- XMLFilter Interface: erweitert XMLReader um 2 Methoden:
  - **`void setParent(XMLReader parent)`** und **`XMLReader getParent()`**
  - "parent" = Reader, auf den der Filter horchen muss
  - Mittels **`setContentHandler`**, etc. werden die Event Handler der Applikation beim Filter registriert.
- Implementierung des XMLFilter Interface:
  - "per Hand": ziemlich aufwändig (XMLReader hat 14 Methoden)
  - Eleganterer Weg: mittels XSLT Stylesheet kann ein XMLFilter automatisch erzeugt werden (späterer VL-Termin).
  - Die Klasse XMLFilterImpl in org.xml.sax.helpers stellt einen Default-Filter bereit, der die Requests in beiden Richtungen transparent durchreicht.

5.3. Document Object Model - DOM

- Überblick DOM
- DOM und JAXP
- Node-Interface
- Einige Subinterfaces von Node
- Weitere Interfaces

Überlick DOM

- DOM-Entwicklung
- DOM-Baumstruktur
- Knoten-Eigenschaften
- DOM Interfaces

DOM-Entwicklung

- DOM: Document Object Model
- W3C-Recommendation: http://www.w3.org/DOM/
- DOM-Versionen in Form von "Levels":
  - Level 0 (keine Recommendation): nur HTML, für JavaScript in Browsern
  - Level 1: Unterstützung von XML 1.0 und HTML 4.0
  - Level 2: Namespaces im Element/Attribute Interface, erweiterte Baum-Manipulationsmöglichkeiten, etc.
  - Level 3: Laden/Speichern, XPath, etc.
- Programmiersprachen-unabhängig
- DOM definiert:
  - logische Struktur eines XML-Dokuments (als Baum)
  - Methoden zum Navigieren und zum Manipulieren des Baumes

DOM-Baumstruktur

- XML Dokument wird als Baumstruktur dargestellt
  - Dieser Baum ist im allgemeinen detaillierter als im Xpath/XSLT Datenmodell (z.B.: eigene Knoten für Entity, CDATA-Section, etc.)
  - Knoten des Baums sind vom Typ "Node"
- Die verschiedenen Knoten-Arten erben von "Node":
  - Document : hier ist der ganze DOM-Baum "aufgehängt"
  - Element, Attr, Text, ProcessingInstruction, Comment
  - DocumentFragment, DocumentType, Entity, CDATASection, EntityReference, Notation
- Wichtige Knoten-Eigenschaften:
  - nodeName, nodeValue, nodeType, attributes

Arbeitsweise von DOM-Parsern

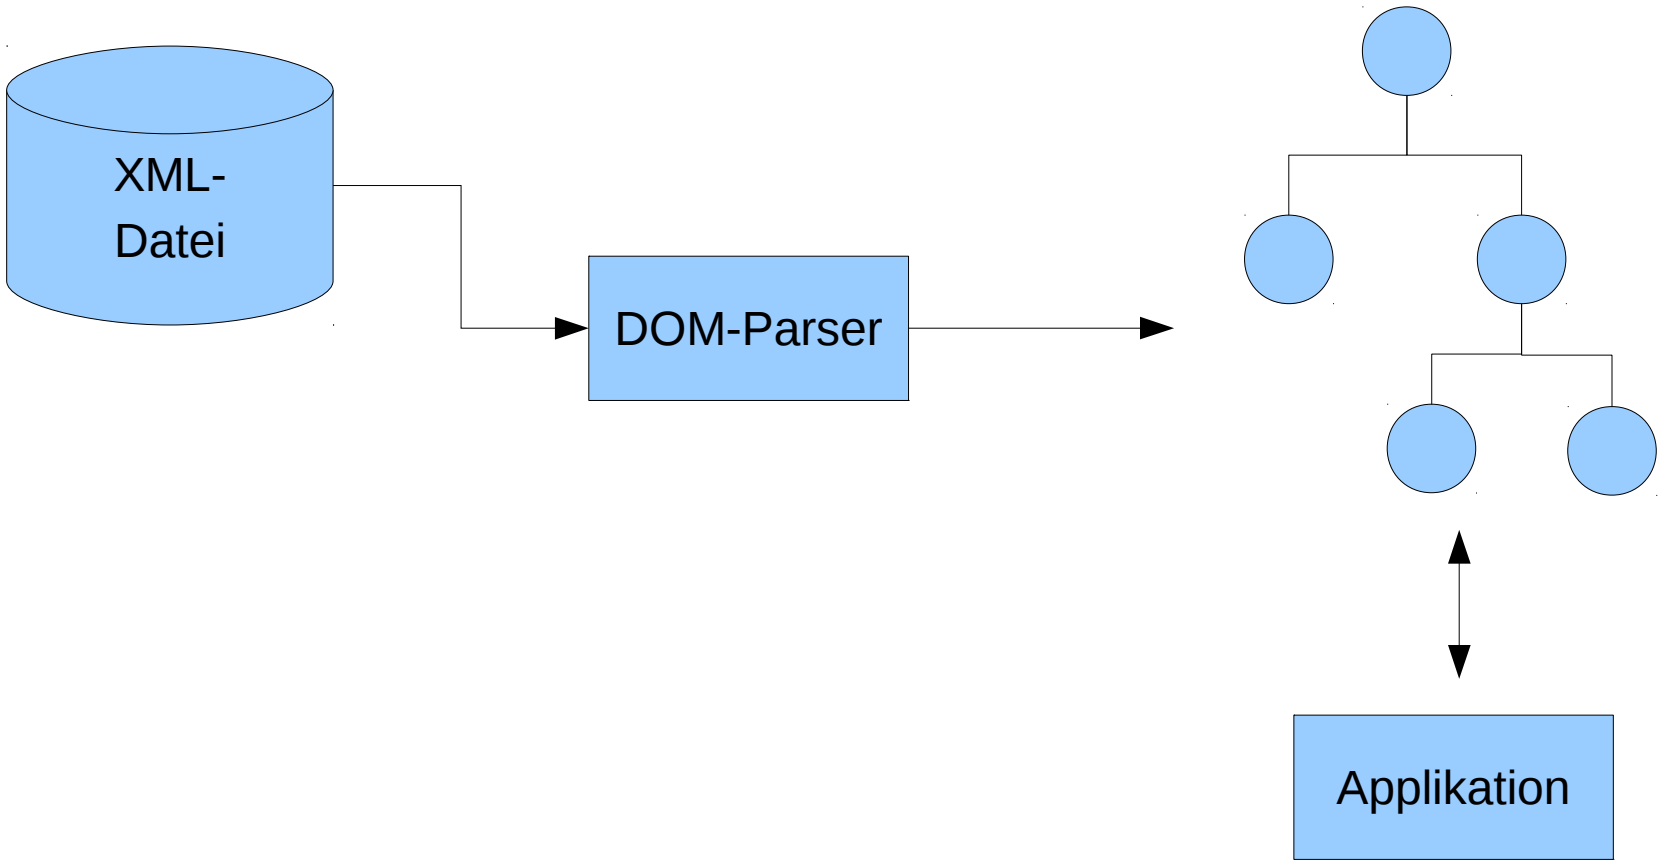

Beispiel für einen DOM-Baum

```
<sentence>
  The &projectName; <![CDATA[<i>project</i>]]> is
  <?editor: red?><bold>important</bold><?editor: normal?>.
</sentence>
```

Dazugehöriger DOM-Baum:

+ Element: sentence
    + Text: The
    + EntityReference: projectName
        + Text: Eagle
    + CDATASection: project
    + Text: is
    + ProcessingInstruction: editor: red
    + Element: bold
        + Text: important
    + ProcessingInstruction: editor: normal
    + Text: .

Hierarchie der DOM-Objekte (1)

- Erlaubte Kinder eines Document Objekts
  - DocumentType (max. 1)
  - Element (max. 1)
  - Processing Instruction
  - Comment

- Erlaubte Kinder eines Element Objekts (gilt auch für DocumentFragment, Entity oder EntityReference):
  - Element
  - Processing Instruction
  - Comment
  - Text
  - CDATASection
  - EntityReference

Hierarchie der DOM-Objekte (2)

- Erlaubte Kinder eines Attr Objekts
  - Text
  - EntityReference
- Objekte ohne weitere Kinder
  - DocumentType
  - Processing Instruction
  - Comment
  - Text
  - CDATASection
  - Notation

Knoten-Eigenschaften

Interface	nodeName	nodeValue	attributes
Attr	name of attribute	value of attribute	null
CDATASection	`"#cdata-section"`	content of the CDATA Section	null
Comment	`"#comment"`	content of the comment	null
Document	`"#document"`	null	null
DocumentFragment	`"#document-fragment"`	null	null
DocumentType	document type name	null	null
Element	tag name	null	NamedNodeMap
Entity	entity name	null	null
EntityReference	name of entity referenced	null	null
Notation	notation name	null	null
ProcessingInstruction	target	entire content excluding the target	null
Text	`"#text"`	content of the text node	null

DOM-Interfaces

- Zentrales Interface: **Node**
  - Gemeinsame Methoden der Knoten des DOM-Baums
  - Navigieren im Baum, Manipulieren des Baums (Knoten löschen/einfügen/ändern), Knoten-Eigenschaften (lesen,schreiben), etc.
- Subinterfaces von Node für jeden Knotentyp
  - Stellen spezifische Methoden zur Verfügung
- Weitere Interfaces:
  - **`NamedNodeMap`**: Sammlung von Knoten, auf die mittels Name oder Index zugegriffen werden kann.
  - **`NodeList`**: Sammlung von Knoten, auf die mittels Index zugegriffen werden kann
  - **`DOMImplementation`**: Erlaubt das Auslesen und Setzen von "Features" der DOM-Implementierung.

DOM und JAXP

- Das Java API hält sich streng an die W3C Vorgabe
- Der **`DocumentBuilder`** liest und erzeugt den DOM-Baum
- Der **`DocumentBuilder`** wird via Factory erzeugt
  - Factories ermöglichen es den Parser transparent zu tauschen
- Features werden über die Factory gesetzt (bevor der **`DocumentBuilder`** erzeugt wird).

Java Mindest-Code (1)

- Importe: DOMBuilder/Factory, DOM:

```
import javax.xml.parsers.DocumentBuilder;
import javax.xml.parsers.DocumentBuilderFactory;
import org.w3c.dom.Document;
import org.xml.sax.SAXException;
import org.xml.sax.SAXParseException;
```

- Factory-Instanzierung:

```
DocumentBuilderFactory factory =
  DocumentBuilderFactory.newInstance();
```

- Parser-Instanzierung und Parsen:

```
DocumentBuilder builder =
  factory.newDocumentBuilder();
Document document = builder.parse(new
  File(filename));
```

Java Mindest-Code (2)

- Einstellungen des Parsers:

```
Document document;
DocumentBuilderFactory factory =
   DocumentBuilderFactory.newInstance();
factory.setValidating(true);
factory.setNamespaceAware(true);
factory.setIgnoringComments(true);
factory.setIgnoringElementContentWhitespace(true);


DocumentBuilder builder =
  factory.newDocumentBuilder();
Document document = builder.parse(new
  File(filename));
```

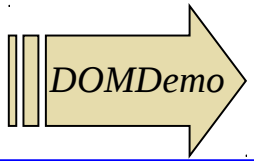

dbai

Einige weitere Anweisungen

- Neuen DOM-Baum erzeugen:

```
DocumentBuilderFactory factory =
DocumentBuilderFactory.newInstance();
DocumentBuilder builder =
  factory.newDocumentBuilder();

Document document = builder.newDocument();
```

- Neuen Knoten erzeugen und einfügen:

```
Element root = document.createElement("test");
document.appendChild(root);
root.appendChild(document.createTextNode("Some
  Text"));
```

Node-Interface

- Node Properties
- Navigation im Baum
- Manipulation des Baums
- Utilities

Node Properties

- `public String getNodeName();`
- `public String getNodeValue() throws DOMException;`
- `public void setNodeValue(String nodeValue) throws DOMException;`
- `public short getNodeType();`
- `public String getNamespaceURI();`
- `public String getPrefix();`
- `public void setPrefix(String prefix) throws DOMException;`
- `public String getLocalName();`

Navigation im Baum

```
public Node         getParentNode();
public boolean      hasChildNodes();
public NodeList     getChildNodes();
public Node         getFirstChild();
public Node         getLastChild();
public Node         getPreviousSibling();
public Node         getNextSibling();
public Document     getOwnerDocument();
public boolean      hasAttributes();
public NamedNodeMap getAttributes();
```

Manipulation des Baums

- `public Node insertBefore(Node newChild, Node refChild) throws DOMException;`
- `public Node replaceChild(Node newChild, Node oldChild) throws DOMException;`
- `public Node removeChild(Node oldChild) throws DOMException;`
- `public Node appendChild(Node newChild) throws DOMException;`

- Beispiele:
  - Die Methode **`removeChild`** entfernt den Knoten **`oldChild`** aus dem DOM-Baum und liefert diesen Knoten als Ergebnis zurück.
  - **`replaceChild`** ersetzt den Knoten **`oldChild`** durch **`newChild`** im DOM-Baum und liefert **`oldChild`** als Ergebnis zurück.

Utilities

- `boolean isEqualNode(Node arg);`
- `boolean isSameNode(Node other);`
- `public Node cloneNode(boolean deep);`

```
// Bei deep = true wird der gesamte Subbaum kopiert.
// Ansonsten nur der einzelne Knoten.
```

- `public void normalize();`

```
// eliminiert leere Text-Knoten und verschmilzt
// benachbarte Text-Knoten im ganzen Subbaum
```

- `public String getTextContent() throws DOMException;`

```
// liefert bei Element-Knoten den gesamten Text-Inhalt
// im Unterbaum. Diesen müsste man sonst aus allen
Text-,
// CDATASection- und EntityReference-Knoten
zusammensuchen.
```

Einige Subinterfaces von Node

- Überblick
- Document Interface
- Element Interface
- Attr Interface
- CharacterData, Text, Comment, CDATASection

Überblick

- Alle Subinterfaces von Node:

```
Attr                  Element
CDATASection          Entity
CharacterData         EntityReference
Comment               Notation
Document              ProcessingInstruction
DocumentFragment      Text
DocumentType
```

Document Interface (1)

- Der DOM-Baum ist an einem Document-Knoten aufgehängt.
- Jeder DOM-Knoten ist einem Document Knoten zugeordnet.
- Das Document Interface bietet Methoden, um neue Knoten (für diesen DOM-Baum) zu erzeugen oder um Knoten aus einem anderen Baum zu importieren.

```
Node adoptNode(Node source) throws DOMException
   // gibt dem Knoten "source" ein neues "ownerDocumnet"
   // und entfernt ihn von der Kinder-Liste seines Parent.
```

```
Node importNode(Node importedNode, boolean deep)
        throws DOMException
  // erzeugt eine Kopie des importierten Knoten sowie
  // (bei deep = true) des gesamten Subbaums.
```

Document Interface (2)

- `Attr createAttribute(String name) throws DOMException`
- `Element createElement(String tagName) throws DOMException`
- `Text createTextNode(String data) ...`

- `DocumentType getDoctype()`
  `// direkter Zugriff zum DocumentType Kind-Knoten`
- `Element getDocumentElement()`
  `// direkter Zugriff zum einzigen Element Kind-Knoten`
- `Element getElementById(String elementId)`
  `// sucht nach dem Element mit diesem ID-Attribut`
- `NodeList getElementsByTagName(String tagname);`
  `// liefert alle Elemente mit diesem Namen im Dokument`

Element Interface (1)

- Einige wesentliche Funktionen sind nicht Element-spezifisch sondern werden vom Node Interface geerbt, z.B.: getAttributes(), getName(), Navigation im Baum
- Das Element Interface bietet einige nützliche Zusatz-Funktionen.

```
NodeList getElementsByTagName(String name)
    // liefert alle Element mit diesem Namen im Subbaum
boolean hasAttribute(String name)
    // hat das Element ein Attribut mit diesem Namen?
```

Element Interface (2)

- `String getAttribute(String name)`
  `// liefert den Wert des Attributes "name"`
- `void setAttribute(String name, String value) throws DOMException`
  `// erzeugt oder überschreibt Attribut mit diesem Wert.`
- `void removeAttribute(String name) throws DOMException`
  `// löscht das Attribut mit diesem Wert.`

- `Attr getAttributeNode(String name)`
  `// liefert den Knoten des Attributes "name"`
- `Attr setAttributeNode(Attr newAttr) throws DOMException`
  `// fügt ein neues Attribut ein (oder ersetzt ein altes mit`
  `// dem selben Namen.`
- `Attr removeAttributeNode(Attr oldAttr) throws DOMException`

Attr Interface

- Attribute gelten nicht als Kinder eines Elements.
- Sie müssen entweder mit getAttributes() oder (falls der Name bekannt ist) mit getAttribute() geholt werden.
- Das Attr Interface bietet nur wenige Erweiterungen gegenüber dem Node Interface, z.B.:

```
Element getOwnerElement()
    // liefert zugehörigen Element Knoten
boolean isId()
    // hat das Attribut den Typ ID?
getValue(), setValue(String value), getName():
analog zu getNodeValue, setNodeValue, getNodeName
```

CharacterData Interface

- Bildet eine "Zwischenebene" zwischen Node Interface und den Interfaces **`CDATASection, Comment, Text`**
- Bietet die "typischen" String-Manipulationen, z.B.:

```
String getData()throws DOMException
   // liefert die Text-Daten des Knotens
void setData(String data) throws DOMException
int getLength()
String substringData(int offset, int count)throws DOMException
void appendData(String arg) throws DOMException
void insertData(int offset, String arg) throws DOMException
ähnlich: deleteData, replaceData (mit offset+count)
```

Text, Comment, CDATASection

- Comment erbt von CharacterData ohne Erweiterungen
- CDATASection erbt von Text ohne Erweiterungen
- Text erbt von CharacterData und bietet einige wenige Erweiterungen, z.B.:
- `String getWholeText()`

```
// liefert Text von diesem Knoten plus von allen
// benachbarten Text-Knoten
```

- `boolean isElementContentWhitespace()`

```
// d.h. whitespace wo Element-Inhalt stehen müsste,
// häufig als "ignorable whitespace" bezeichnet
```

Weitere Interfaces

- NodeList
- NamedNodeMap
- XPath

NodeList

- Praktisch zum Abarbeiten von Knotenmengen (z.B. alle Kinder eines Knoten, alle Elemente mit einem bestimmten Namen,..)
- Lesender Zugriff
- hat nur 2 Methoden:

```
int getLength()
    // liefert Anzahl der Knoten in der NodeList
Node item(int index)
    // wahlfreier Zugriff mittels index
    // (der bei 0 beginnt)
```

Beispiel

- Suche nach dem ersten Subelement mit einem betimmten Namen:

```
public Node findSubNode(String name, Node node) {
   if (! node.hasChildNodes()) return null;
   NodeList list = node.getChildNodes();
   for (int i=0; i < list.getLength(); i++) {
      Node subnode = list.item(i);
      if (subnode.getNodeType() == Node.ELEMENT_NODE) {
         if (subnode.getNodeName().equals(name)) return subnode;
               else {
                     Node tmp = findSubNode(name, subnode);
                     if(tmp!=null) return tmp;}}
   }  }  }
   return null;
}
```

Beispiel (Alternative)

- Suche nach dem ersten Subelement mit einem betimmten Namen:

```
public Node findSubNode(String name, Node node) {
        NodeList nl;
        if(node.getNodeType()==Node.ELEMENT_NODE) {
                nl = ((Element)node)).getElementsByTagName(name);
        } else if (node.getNodeType()==Node.DOCUMENT_NODE) {
                nl = ((Document)node).getElementsByTagName(name);
        }
        if(nl!=null && nl.getLength() > 0) // nicht unb. nötig
                return nl.item(0);
        return null;
}
```

NamedNodeMap (1)

- Zugriff auf Knoten in einer NamedNodeMap:
  - Entweder mittels Name oder mittels Index. Im Gegensatz zu NodeList haben die Knoten einer NamedNodeMap keine definierte Reihenfolge
- Schreibender oder lesender Zugriff
- Wird vorwiegend für Attribute verwendet
- `int getLength()`

  `// liefert Anzahl der Knoten in der NamedNodeMap`
- `Node item(int index)`

  `// wahlfreier Zugriff mittels index`

  `// (der bei 0 beginnt)`

NamedNodeMap (2)

- **Node getNamedItem(String name)**
  // liefert Knoten mit diesem Namen
- **Node setNamedItem(Node arg) throws DOMException**
  // fügt einen neuen Knoten ein (oder ersetzt einen alten
  // mit dem selben Namen.
- **Node removeNamedItem(String name) throws DOMException**
  // entfernt den Knoten mit diesem Namen und liefert
  // den Knoten zurück.

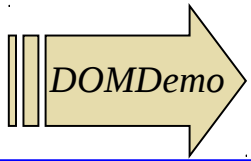

dbai

XPath

- Möglichkeit zur Evaluierung von XPath-Ausdrücken
- Lesender Zugriff

```
XPathExpression compile(String exp)
// Kompiliert einen XPath-Ausdruck zur
//späteren Evaluierung
String evaluate(String exp, InputSource source)
// Evaluiert einen XPath-Ausdruck im Kontext des
//spezifizierten InputSource und liefert einen String
Object evaluate(String exp, InputSource source, QName
   returnType)
// Evaluiert einen XPath-Ausdruck im Kontext des
//spezifizierten InputSource und liefert das Ergebnis als
//spezifizierten Typ
```

Beispiel

- Liefere alle “Task” Knoten:

```
public NodeList getAllTasks(Document taskDocument) {
   XPath evaluator = XPathFactory.newInstance().newXPath();
   NodeList taskNodes = (NodeList)evaluator.evaluate(“//task”,
   taskDocument, XPathConstants.NODESET);
   return taskNodes;
}
```

5.4. XML-Ausgabe

- Überblick
- Ausgabe mittels Transformer
  - SAX
  - DOM
- Ausgabe mittels LSSerializer
  - DOM

Überblick

- **XML-Dokument ausgeben/schreiben:**
- mittels Transformer (SAX, DOM)

  Eigentlich für XSLT-Transformationen gedacht
  Erlaubter Input: StreamSource, DOMSource oder SAXSource
  Erlaubter Output: StreamResult, DOMResult oder SAXResult
  Ohne Angabe eines XSLT-Stylesheets wird ein XML-Dokument einfach von einem der Input-Formate in eines der Output-Formate umgewandelt.
- mittels LSSerializer (DOM)

  In DOM Level 3 wurde "Load and Save" Modul ergänzt
  Eigenes Package: org.w3c.dom.ls
  Interface LSSerializer: zur "Umwandlung" in ein XML-Dokument.

SAX-Ausgabe mittels "Transformer" (1)

- Output des XMLReaders als XML-Dokument
  - mittels "transformer", analog zur DOM-Ausgabe, d.h.:
    - Erzeuge mittels XMLReader eine SAXSource
    - Aufruf des transformers mit dieser SAXSource als Input

- Importe
  - wie bei DOM:

```
import javax.xml.transform.Transformer;
import javax.xml.transform.TransformerFactory;
import javax.xml.transform.stream.StreamResult;
```

  - SAX-spezifische Importe:
    - `import javax.xml.transform.sax.SAXSource;`
    - `import org.xml.sax.InputSource;`

SAX-Ausgabe mittels "Transformer" (2)

- Transformer-Instanzierung (wie bei DOM):

```
TransformerFactory tFactory =
 TransformerFactory.newInstance();
Transformer transformer = tFactory.newTransformer();
```

- Ausgabe (d.h.: erzeuge SAXSource mittels XMLReader)

```
SAXSource source =
 new SAXSource(reader, new InputSource(quelle));
StreamResult result = new StreamResult(new File(ziel));
transformer.transform(source, result);
```

DOM-Ausgabe mittels "Transformer"

- Importe:

```
import javax.xml.transform.Transformer;
import javax.xml.transform.TransformerFactory;
import javax.xml.transform.dom.DOMSource;
import javax.xml.transform.stream.StreamResult;
```

- Transformer instanzieren:

```
TransformerFactory tFactory =
   TransformerFactory.newInstance();
Transformer transformer =
   tFactory.newTransformer();
```

DOM-Ausgabe mittels "Transformer"

- Ausgabe:
  - ```
    DOMSource source = new DOMSource(document);
    StreamResult result =
       new StreamResult(new File("output.xml"));
    transformer.transform(source, result);
    ```

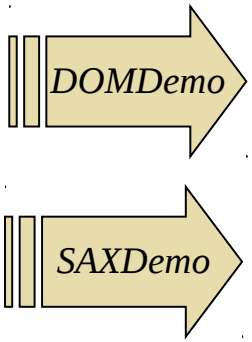
    ```

DOM-Ausgabe mittels "LSSerializer"

- Voraussetzung:
  - Die verwendete DOM-Implementierung muss DOM 3.0 unterstützen.
  - In diesem Fall implementiert die DOMImplementation das erweiterte Interface DOMImplementationLS.
  - DOMImplementationLS bietet eine Factory zum Erzeugen von einem LSSerializer.

- Importe:

```
import org.w3c.dom.ls.DOMImplementationLS;
import org.w3c.dom.ls.LSSerializer;
```

DOM-Ausgabe mittels "LSSerializer"

- LSSerializer instanzieren:

```
DOMImplementation di =
   document.getImplementation();
if (di.hasFeature("Core","3.0")){
  DOMImplementationLS diLS =
   (DOMImplementationLS) di;
  LSSerializer lss = diLS.createLSSerializer();
  …
};
```

- Ausgabe:

```
FileWriter fw = new FileWriter("output.xml");
fw.write(lss.writeToString(document));
fw.flush();
fw.close();
```

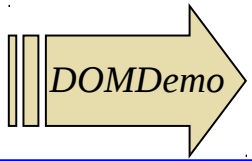

dbai

5.5. Epilog

- DOM vs. SAX
- Literatur

DOM vs. SAX

DOM:

- Baut gesamten XML-Baum im Speicher auf => wahlfreier Zugriff
- Manipulation des Baums möglich
- Hoher Speicherbedarf, langsamer

SAX:

- XML-Dokument wird einmal durchlaufen => sequentieller Zugriff
- "streaming" möglich (d.h.: Bearbeiten und Weiterreichen, bevor das ganze Dokument übertragen ist).
- Geringerer Speicherbedarf, höhere Geschwindigkeit
- Falls mehrmaliger Zugriff auf Knoten erforderlich: Applikation ist selbst für das Puffern verantwortlich.
- Low level (aktuelle DOM-API benutzt SAX-API)

Literatur

- Spezifikationen:
  - http://www.w3.org/DOM/
  - http://www.saxproject.org/
- (Online) Bücher und Artikel:
  - Elliotte Rusty Harold: "Processing XML with Java"
    - http://www.cafeconleche.org/books/xmljava/
  - J2EE Tutorial (Kap. 4-7):
    - http://java.sun.com/j2ee/1.4/docs/tutorial/doc/